

LAPORAN PRAKTIKUM
EKSPLORASI DATASET SEKUNDER DAN STUDI
KOMPARASI KINERJA ALGORITME KLASIFIKASI

Studi Kasus: Klasifikasi Kategori Produk Retail



Disusun Oleh: Muhammad Nadhif

240210502042

Sistem Cerdas B

PRODI TEKNIK KOMPUTER
JURUSAN TEKNIK INFORMATIKA DAN KOMPUTER
FAKULTAS TEKNIK
UNIVERSITAS NEGERI MAKASSAR
2026

1. Deskripsi dan Pemahaman Data

1.1 Sumber Data

Dataset yang digunakan dalam analisis ini adalah data produk retail (retail_product_dataset_300.csv) yang berisi atribut deskriptif dan numerik dari sejumlah produk yang dijual pada beberapa kategori. Dataset terdiri atas 300 baris data dan 5 kolom, mencakup 4 atribut prediktor (price, rating, stock, discount) dan 1 kolom target (category).

1.2 Domain Permasalahan

Dataset ini berisi atribut transaksional produk retail yaitu harga jual, rating ulasan pelanggan, status ketersediaan stok, dan besaran diskon. Atribut-atribut tersebut digunakan untuk memprediksi kategori produk yang diwakili oleh label category. Pada analisis ini, dataset digunakan untuk pemodelan klasifikasi multi-kelas guna mengelompokkan produk ke dalam lima kategori: Beauty, Clothing, Electronics, Home & Kitchen, dan Sports.

1.3 Preprocessing

Data awal berukuran 300 baris dan 5 kolom (4 atribut prediktor dan 1 atribut target). Hasil pengecekan kualitas data menunjukkan kondisi yang jauh berbeda dari dataset kendaraan bekas pada studi pembandingan:

- Ditemukan missing value pada tiga dari empat atribut prediktor: price (8 baris), rating (13 baris), stock (7 baris), dan discount (14 baris). Tidak ada missing value pada kolom target.
- Tidak ditemukan data duplikat pada seluruh baris data. Atribut stock bertipe kategorikal sehingga diubah menjadi variabel dummy (one-hot encoding) melalui `pd.get_dummies` dengan `drop_first=True`, menghasilkan dua kolom biner tambahan: `stock_Low Stock` dan `stock_Out of Stock`.
- Missing value pada atribut numerik (price, rating, discount) diisi menggunakan `SimpleImputer` dengan strategi median, bukan dengan penghapusan baris, agar ukuran data latih tetap terjaga.
- Tidak dilakukan penghapusan kolom identifier karena dataset tidak menyertakan kolom id/nomor urut.

Setelah tahap pemeriksaan dan imputasi, dataset siap digunakan dengan 5 fitur prediktor (price, rating, discount, `stock_Low Stock`, `stock_Out of Stock`) dan 1 target multi-kelas (category) sebanyak 300 baris. Distribusi kelas target

Berbeda dengan dataset kendaraan bekas pada studi pembandingan yang memiliki distribusi kelas seimbang sempurna (33,33% untuk setiap kelas), distribusi kelas pada dataset retail ini bersifat sedikit tidak seimbang (imbalanced ringan), dengan kelas Beauty mendominasi (24,67%) dan kelas Clothing menjadi kelas minoritas (15,33%).

2. Pemodelan Naive Bayes dan Audit Parameter Distribusi

2.1 Pelatihan Model Naive Bayes

Scikit-learn menyediakan beberapa varian Naive Bayes untuk tipe data yang berbeda, di antaranya `GaussianNB` untuk atribut numerik kontinu, serta `CategoricalNB` untuk atribut kategorikal atau diskrit. Karena kelima fitur hasil preprocessing (price, rating, discount, `stock_Low Stock`, `stock_Out of Stock`) telah berbentuk numerik, model yang dipilih pada notebook ini adalah Gaussian Naive Bayes, dengan asumsi bahwa nilai tiap atribut berdistribusi normal (Gaussian) pada masing-masing kelas target.

Model kemudian dilatih menggunakan 240 sampel data latih (80% dari total 300 data) yang telah dipisahkan pada tahap sebelumnya, dengan pembagian data uji sebanyak 60 sampel (20%) secara stratifikasi (`stratify=target`) agar proporsi kelima kelas pada data latih dan data uji tetap konsisten dengan proporsi aslinya.

2.2 Parameter yang Dipelajari

Setelah model dilatih, ada tiga parameter internal yang dapat diambil dari Gaussian Naive Bayes: probabilitas prior tiap kelas, rata-rata tiap atribut, dan varians tiap atribut, yang masing-masing dihitung terpisah untuk kelima kelas produk.

Probabilitas prior menunjukkan proporsi awal tiap kelas di data latih, sebelum atributnya dilihat sama sekali.

Nilai prior yang tidak seragam di atas mencerminkan proporsi kelas pada data latih yang sedikit timpang, konsisten dengan distribusi kelas pada Tabel 1.5 di atas — berbeda dengan studi perbandingan pada dataset kendaraan bekas yang priornya identik 0,3333 untuk seluruh kelas.

Rata-rata dan varians tiap atribut ditampilkan pada tabel di bawah. Kedua nilai ini digunakan oleh model untuk menghitung peluang suatu sampel produk masuk ke kelas tertentu, dengan asumsi bahwa setiap atribut mengikuti distribusi normal pada masing-masing kelas.

Berbeda mencolok dengan studi kasus kendaraan bekas, rata-rata kelima atribut pada dataset retail ini terlihat sangat mirip antar kelas. Sebagai contoh, rata-rata price hanya berkisar antara 240,59 (Clothing) hingga 263,39 (Sports) — selisih kurang dari 10%, dan rata-rata rating hanya berkisar 2,89 hingga 3,24 dari skala 1-5. Pola serupa juga tampak pada discount yang berkisar 13,97-16,30. Nilai-nilai yang hampir seragam ini mengindikasikan bahwa harga, rating, dan diskon suatu produk tidak berhubungan kuat dengan kategori produknya — masuk akal secara bisnis, karena harga dan rating tinggi/rendah dapat dijumpai pada produk kecantikan maupun produk elektronik. Hal ini menjadi pertanda awal bahwa atribut yang tersedia kemungkinan besar tidak cukup informatif untuk membedakan kelima kategori produk secara akurat.

2.3 Inferensi pada Data Uji

Model diuji dengan dua fungsi keluaran yang berbeda, yaitu `predict()` untuk penentuan label kelas secara langsung, dan `predict_proba()` untuk menghitung estimasi probabilitas posterior tiap kelas. Perbandingan hasil dari 5 sampel data uji pertama

Berbeda jauh dengan studi kasus kendaraan bekas yang confidence-nya di atas 99% pada hampir seluruh prediksi, tabel di atas memperlihatkan probabilitas posterior yang tersebar cukup merata di antara kelas-kelas (berkisar 0,11 hingga 0,41). Model tidak pernah benar-benar "yakin" terhadap satu kelas tertentu, yang mengindikasikan sejak awal bahwa kelima atribut prediktor tidak memberikan sinyal pembeda yang kuat antar kategori produk. Dari 5 sampel di atas, hanya 3 yang berhasil diprediksi dengan tepat, dan model cenderung bias menebak kelas Beauty (kelas dengan prior tertinggi) ketika sinyal atributnya lemah.

3. Pemodelan Komparasi Multi-Algoritme

Selain Gaussian Naive Bayes, penelitian ini memakai lima algoritme lain sebagai pembandingan, yaitu Decision Tree, K-Nearest Neighbors (KNN), Logistic Regression, Random Forest, dan Support Vector Machine (SVM). Keenamnya dipilih karena cara kerjanya berbeda satu sama lain, sehingga hasil perbandingannya dengan Naive Bayes bisa lebih bermakna, bukan sekadar membandingkan model yang mirip.

- Decision Tree: membentuk struktur pohon keputusan yang membagi data secara bertingkat berdasarkan ambang nilai tiap atribut (kriteria gini), hingga kedalaman maksimum 5 tingkat.
- K-Nearest Neighbors (KNN): menentukan kelas suatu data dengan melihat data lain yang paling dekat atau paling mirip, dalam hal ini diambil 5 tetangga terdekat berbasis jarak Euclidean.
- Logistic Regression: memprediksi kelas berdasarkan peluang suatu data masuk ke kelas tertentu, dihitung dari kombinasi linear atribut yang dipetakan lewat fungsi softmax untuk kasus multi-kelas.
- Random Forest: menggabungkan 100 Decision Tree yang masing-masing dilatih dari sebagian data dan atribut yang berbeda-beda, kemudian hasil akhirnya diambil dari voting mayoritas seluruh pohon tersebut

4. Evaluasi Kinerja dan Visualisasi Komparatif

4.1 Perbandingan Metrik Performa


Seluruh model dievaluasi pada partisi data uji yang sama sebanyak 60 sampel memakai empat metrik standar: Akurasi, Presisi, Recall, dan F1-Score (rata-rata macro). Hasil perbandingan performanya dapat dilihat pada tabel berikut.

Algoritme	Akurasi	Presisi	Recall	F1-Score
Gaussian Naive Bayes	0,2000	0,0826	0,1641	0,1066
Decision Tree	0,1667	0,1591	0,1571	0,1517
K-Nearest Neighbors	0,2000	0,1382	0,1640	0,1467
Logistic Regression	0,2500	0,1402	0,2070	0,1589
Random Forest	0,2000	0,1614	0,1769	0,1673
SVM	0,2167	0,1200	0,1793	0,1407

Berdasarkan F1-Score, model dengan performa tertinggi adalah Random Forest (0,1673), diikuti oleh Logistic Regression (0,1589) dan Decision Tree (0,1517). Namun, hal terpenting yang perlu digarisbawahi adalah bahwa seluruh nilai F1-Score berada jauh di bawah 0,50 — bahkan model terbaik sekalipun hanya sedikit lebih baik daripada tebakan acak. Untuk klasifikasi 5 kelas, akurasi tebakan acak murni secara teoritis adalah $1/5 = 0,20$ (20%); seluruh keenam algoritme di sini menghasilkan akurasi pada kisaran 0,1667-0,2500, yang secara statistik tidak jauh berbeda dari baseline acak tersebut.

4.2 Visualisasi Perbandingan Metrik

Perbandingan keempat metrik antar-algoritme divisualisasikan dalam diagram batang berkelompok pada gambar berikut, dengan anotasi nilai numerik pada setiap batang.




Dari grafik terlihat bahwa keenam batang untuk setiap algoritme relatif rendah dan seragam, tanpa ada satu model pun yang menonjol jauh di atas yang lain — kontras dengan pola pada studi kasus kendaraan bekas di mana Decision Tree dan Random Forest mencapai skor sempurna (1,0000). Pada

dataset retail ini, tidak ada algoritme yang mampu "memecahkan" pola pemisahan kelas karena polanya memang tidak banyak tersedia pada data.

4.3 Visualisasi Matriks Konfusi

Matriks konfusi dievaluasi untuk membandingkan Gaussian Naive Bayes dengan model terbaik, Random Forest. Matriks ini memetakan sebaran prediksi benar dan salah guna melihat pada kelas mana galat klasifikasi terjadi. Hasilnya ditampilkan pada gambar berikut.



Kedua matriks menunjukkan pola yang sama-sama tersebar acak di luar diagonal utama. Pada Naive Bayes, kelas Beauty paling sering diprediksi (bahkan untuk sampel yang aslinya berasal dari kelas lain), sejalan dengan nilai priornya yang tertinggi (0,2458) di antara kelima kelas. Pada Random Forest, kesalahan klasifikasi tersebar cukup merata ke semua kelas tanpa pola dominan yang jelas, mengindikasikan model tidak menemukan aturan pemisah yang konsisten.

5. Pembahasan dan Analisis Kritis

5.1 Algoritme dengan Performa Terbaik

Berdasarkan F1-Score, Random Forest meraih performa tertinggi (0,1673), disusul oleh Logistic Regression (0,1589), Decision Tree (0,1517), KNN (0,1467), SVM (0,1407), serta Gaussian Naive Bayes yang mencatat performa terendah (0,1066). Keunggulan tipis Random Forest kemungkinan besar berasal dari sifatnya sebagai model ensemble yang merata-ratakan banyak pohon acak, sehingga sedikit lebih tahan terhadap derau (noise) pada data yang memang minim pola. Namun keunggulan ini tetap tidak substansial — selisih F1-Score antar-algoritme hanya berkisar 0,06, jauh lebih kecil dibandingkan variasi antar-algoritme pada studi kasus kendaraan bekas (0,0000-0,0303).

5.2 Mengapa Seluruh Model Berkinerja Rendah

Terdapat beberapa indikasi kuat mengapa seluruh algoritme, tanpa terkecuali, gagal mencapai performa yang baik pada dataset ini:

- Rata-rata (mean) tiap atribut numerik antar kelas sangat berdekatan (lihat Tabel Rata-rata pada Bagian 2.2), misalnya price hanya berbeda sekitar 23 satuan antar kelas dengan tertinggi dan terendah, dan rating hanya berbeda sekitar 0,35 poin. Ini menunjukkan atribut prediktor tidak memiliki daya pisah (discriminative power) yang berarti terhadap kategori produk.
- Dari sisi domain permasalahan, kategori produk (Beauty, Electronics, Sports, dsb.) secara konseptual ditentukan oleh jenis/fungsi barang, bukan oleh harga, rating, diskon, atau status stoknya — sebuah produk elektronik dan produk kecantikan sama-sama bisa memiliki harga Rp 250.000, rating 3 bintang, dan status stok apa pun. Berbeda dengan studi kasus kendaraan bekas, di

mana kategori harga memang secara langsung berkorelasi kausal dengan atribut usia, kilometer, dan tenaga kendaraan.

- Ukuran data latih yang terbatas (240 sampel untuk 5 kelas, rata-rata hanya sekitar 48 sampel per kelas) turut membatasi kemampuan model kompleks seperti Random Forest dan SVM untuk menggeneralisasi pola, meskipun pada kasus ini keterbatasan data bukan penyebab utama karena bahkan pada data latih pun pola pemisah antar kelas nyaris tidak terlihat.

5.3 Evaluasi Naive Bayes terhadap Model Pemandang

Ditinjau dari nilai varians pada Bagian 2.2, ditemukan bahwa varians tiap atribut relatif konsisten besarnya antar kelas (misalnya varians price berkisar 16.586 hingga 23.398), sehingga asumsi homogenitas sebaran tidak terlalu dilanggar. Akan tetapi, asumsi independensi antar-atribut pada Naive Bayes berpotensi kurang tepat karena discount dan price bisa jadi saling berkaitan (produk dengan diskon besar cenderung memiliki price awal tertentu). Meskipun demikian, akar masalah utama pada dataset ini bukan pada pelanggaran asumsi algoritmik tertentu, melainkan pada lemahnya hubungan antara seluruh fitur yang tersedia dengan variabel target itu sendiri — sehingga algoritme non-parametrik yang lebih fleksibel seperti Random Forest maupun SVM juga tidak mampu memberikan perbaikan yang berarti dibanding Naive Bayes.

5.4 Analisis Tipe Kesalahan Dominan

Dari evaluasi galat pada Gambar 2, Gaussian Naive Bayes menghasilkan 48 kesalahan klasifikasi dari total 60 data uji (akurasi 20%), dengan kecenderungan model menebak kelas Beauty secara berlebihan (over-prediksi) akibat nilai priornya yang tertinggi. Random Forest menghasilkan 48 kesalahan klasifikasi dengan sebaran yang lebih merata ke semua kelas, tanpa dominasi prediksi pada satu kelas tertentu. Berbeda dengan studi kasus kendaraan bekas, di mana kesalahan klasifikasi hanya terjadi antar kelas yang bersebelahan secara ordinal (Rendah-Sedang, Sedang-Tinggi) dan tidak pernah antar kelas berjauhan, pada dataset retail ini kesalahan terjadi hampir merata ke seluruh pasangan kelas (misalnya Sports salah diklasifikasikan sebagai Beauty, Home & Kitchen, maupun Electronics dengan frekuensi yang sebanding) — pertanda bahwa tidak ada struktur/urutan alami antar kategori produk yang bisa dimanfaatkan model, berbeda dengan kategori harga yang memiliki urutan (ordinal) Rendah < Sedang < Tinggi.

5.5 Kesimpulan

Secara keseluruhan, keenam algoritme klasifikasi yang diuji — Gaussian Naive Bayes, Decision Tree, KNN, Logistic Regression, Random Forest, dan SVM — seluruhnya menghasilkan performa yang mendekati baseline tebakan acak (F1-Score 0,1066-0,1673; akurasi 16,67%-25%) pada dataset retail_product_dataset_300.csv. Hal ini berbeda secara signifikan dengan studi kasus pembandingan pada dataset kendaraan bekas, di mana seluruh model mencapai F1-Score di atas 0,96. Temuan ini menunjukkan bahwa atribut price, rating, stock, dan discount pada dataset ini tidak cukup informatif untuk memprediksi kategori produk, dan bahwa kualitas serta relevansi fitur prediktor terhadap variabel target jauh lebih menentukan keberhasilan model klasifikasi dibandingkan sekadar pemilihan algoritme yang lebih kompleks atau canggih. Untuk meningkatkan performa, diperlukan fitur tambahan yang lebih relevan secara konseptual dengan kategori produk, misalnya nama produk, deskripsi tekstual, brand, atau sub-kategori.